


- A/B Testing
- Multiple Testing
- Hypothesis Tests
- ANOVA
- Resampling & Permutation
- Chi-Square Test
- p-Values & Alpha
- Multi-Arm Bandit
- t-Tests
- Power & Sample Size

CHAPTER 3

Statistical Experiments & Significance Testing

Statistical Inference Pipeline

Tổng quan quy trình suy luận thống kê



Mục tiêu: Xác nhận hoặc bác bỏ hypothesis dựa trên dữ liệu thực nghiệm.

Hypothesis

Giả thuyết cần kiểm định —
ví dụ: 'Drug A tốt hơn drug B'

Experiment

A/B test hoặc randomized experiment

Inference

Áp dụng kết quả từ mẫu lên toàn bộ
population

A/B Testing

Thực nghiệm so sánh hai nhóm

Định nghĩa: So sánh 2 treatment để xác định cái nào vượt trội hơn.

Treatment

Thứ được thử nghiệm: thuốc, giá, headline web...

Control Group

Nhóm không nhận treatment hoặc nhận treatment chuẩn

Randomization

Phân ngẫu nhiên subject vào các nhóm — loại bỏ bias

Test Statistic

Metric đo lường hiệu quả của treatment

Subject

Đối tượng thực nghiệm: visitor, patient, seed...

Blinding

Subject không biết họ thuộc nhóm nào — tránh placebo effect

A/B Testing: Control Group & Metrics

Tại sao cần Control Group?

- Không có control → không đảm bảo 'all other things equal'
- Sự khác biệt có thể do yếu tố khác, không phải treatment
- Control group chịu cùng điều kiện, chỉ khác ở treatment
- Đảm bảo sự khác biệt đến từ treatment hoặc random chance

Chọn Test Statistic

- Binary: click/no-click, buy/not buy, ...
- Continuous: revenue, time on page, profit
- Count: days in hospital, pages visited
- Phải chọn 1 metric TRƯỚC khi chạy thí nghiệm
- Chọn sau → researcher bias

Ví dụ: 2x2 table — Price A vs Price B

Outcome	Price A	Price B
Conversion	200	182
No Conversion	23539	22406

*Price A converts ~5% better than B
(0.8425% vs 0.8057%)*

Hypothesis Tests

Còn gọi là Significance Tests

Mục tiêu: Xác định liệu random chance có thể giải thích kết quả quan sát được không

Null Hypothesis (H_0)

Giả thuyết rằng không có gì đặc biệt. Sự khác biệt là do random chance.

Ví dụ: 'Không có sự khác biệt giữa A và B'

Alternative Hypothesis (H_1)

Đối lập với H_0 — điều ta muốn chứng minh.

Ví dụ: 'A tốt hơn B' hoặc 'A khác B'

One-Way Test

Chỉ đếm kết quả chance theo một hướng.

Phù hợp khi quan tâm đến 'B có tốt hơn A không?'

Two-Way Test

Đếm chance results ở cả hai hướng.

Phù hợp khi hỏi 'A và B có khác nhau không?'

Tại sao cần hypothesis? → Não người có xu hướng nhìn thấy pattern trong randomness → dễ bị 'fooled by chance'

Null Hypothesis & Null Model

Null Hypothesis là gì?

Giả định baseline: hai treatment là tương đương, mọi khác biệt là do chance.

Mục tiêu: Chứng minh được H_0 là sai — kết quả vượt xa chance.

Null Model

Được tạo ra bằng cách: shuffle kết quả A & B lại với nhau, rồi repeatedly deal out data → xem sự khác biệt thường xuất hiện bao nhiêu.

Thí nghiệm Đồng Xu

- “Tưởng tượng 50 lần tung đồng xu
- Sau đó tung thật 50 lần
- Kết quả thật có runs dài (5-6 H liên tiếp)
- Kết quả tưởng tượng quá 'đều' — không tự nhiên
- → Người ta underestimate randomness!

Kết luận

Nếu kết quả observed nằm ngoài phần lớn permutation distribution → 'statistically significant' → chance không giải thích được.

Resampling & Permutation Test

Kiểm định thống kê không cần giả định phân phối

2 Loại Resampling

Bootstrap: đánh giá độ tin cậy của estimate

Permutation Test: kiểm định hypothesis (2+ nhóm)

Variants

Exhaustive (Exact Test): liệt kê tất cả hoán vị — chính xác nhưng tốn kém

Bootstrap: sample with replacement — mô hình cả sampling variability

Quy trình Permutation Test:

- 1 Gộp kết quả tất cả nhóm lại thành 1 dataset
- 2 Shuffle và rút ngẫu nhiên resamples có cùng kích thước với từng nhóm
- 3 Tính test statistic (ví dụ: chênh lệch mean) cho resamples
- 4 Lặp lại R lần (thường 1,000+) → tạo permutation distribution
- 5 So sánh observed difference với permutation distribution

Ví dụ: Web Page Stickiness

Permutation Test thực tế

Bài toán

Metric: Average session time (proxy cho sales)

Page A: 21 sessions | Page B: 15 sessions

Observed difference: Page B – Page A = 35.67 giây

Proxy Variable

Biến thay thế cho outcome thực sự (sales) khi sales quá hiếm để đo trực tiếp.

```
# Python – Permutation function
def perm_fun(x, nA, nB):
    idx_B = set(random.sample(range(nA+nB), nB))
    idx_A = set(range(nA+nB)) - idx_B
    return x.loc[idx_B].mean() - x.loc[idx_A].mean()

perm_diffs = [perm_fun(session_times.Time, 21, 15) for _ in range(1000)]
```

Kết quả R

12.6% permutations vượt observed difference


Kết quả Python

12.1% permutations vượt observed difference

Kết luận

Observed diff nằm trong vùng chance variation → NOT statistically significant

Ví dụ: Web Page Stickiness



p-Value & Statistical Significance

p-value = tần suất mà chance model tạo ra kết quả extreme hơn hoặc bằng observed result

p-value nhỏ ($< \alpha$)

Kết quả hiếm dưới null model → reject H_0
→ statistically significant

Alpha (α)

Ngưỡng được xác định TRƯỚC khi thí nghiệm
Thường: 5% hoặc 1%
Alpha càng nhỏ → tiêu chí càng nghiêm

Ý nghĩa thực tế (Practical Significance)

Statistical significance $\neq$ practical significance
Sample lớn → detect được effect nhỏ vô nghĩa
→ Luôn kiểm tra effect size

⚠ ASA 2016: p-value không đo xác suất H_0 đúng. Không nên dùng một mình để ra quyết định khoa học.

Type 1 Error

Kết luận effect là thật khi thực ra là chance (False Positive)

Type 2 Error

Kết luận không có effect khi thực ra có (False Negative — thường do sample nhỏ)

t-Tests

Công cụ kiểm định phổ biến cho dữ liệu numeric

Bối cảnh lịch sử

Thập niên 1920–30, chưa có máy tính → không thể shuffle hàng nghìn lần. Statisticians tìm xấp xỉ phân phối shuffle = t-distribution (Gosset). Ngày nay permutation test được ưu tiên trong data science.

t-statistic

Standardized version của test statistic (difference of means)
$$= (\text{mean_A} - \text{mean_B}) / \text{standard error}$$

t-distribution

Reference distribution (null hypothesis) để so sánh t-statistic
Phụ thuộc vào degrees of freedom

Welch t-test

Biến thể không yêu cầu equal variance giữa 2 nhóm
Đây là default trong hầu hết phần mềm

```
# R
t.test(Time ~ Page,
       data=session_times,
       alternative='less')
# p-value = 0.1408

# Python
from scipy import stats
res = stats.ttest_ind(a, b,
                     equal_var=False)
# p-value / 2 = 0.1405
```

Note: p-value từ t-test (0.1408) xấp xỉ với permutation test (0.121–0.126) → nhất quán

Multiple Testing

"Torture the data long enough, and it will confess"

Vấn đề: Càng hỏi nhiều câu hỏi trên cùng dữ liệu → xác suất tìm thấy 'significant' result do chance càng tăng.

Alpha Inflation

Ví dụ: 20 biến độc lập, kiểm định từng biến ở $\alpha = 0.05$

$P(\text{tất cả đều nonsignificant}) = 0.95^{20} = 0.36$

$P(\text{ít nhất 1 false significant}) = 1 - 0.36 = 0.64$

→ 64% cơ hội false positive chỉ do chance

Cho Data Scientists

Predictive modeling: dùng cross-validation và holdout set

Exploratory analysis: nhận thức rằng data manipulation nhiều hơn → chance nhiều hơn

Dùng resampling để benchmark kết quả với random variation

False Discovery Rate

Tỷ lệ false positives trong tập test

Phổ biến trong genomics research

Bonferroni Adjustment

Chia alpha cho số lần test

$\alpha_{\text{new}} = \alpha / n_{\text{tests}}$

Tukey's HSD

So sánh maximum difference giữa group means

Dùng cho multi-group ANOVA

ANOVA — Analysis of Variance

Mở rộng A/B test cho nhiều nhóm (A/B/C/D...)

Mục đích

Thay vì $N(N-1)/2$ pairwise comparisons → 1 omnibus test tổng thể giảm nguy cơ Multiple Testing.

F-statistic

$= MS(\text{treatment}) / MS(\text{error})$

Tỷ lệ variance giữa nhóm / variance trong nhóm

Càng cao → khác biệt càng có ý nghĩa

Permutation Approach

Gộp tất cả data → shuffle → chia thành các nhóm cùng kích thước → tính variance giữa nhóm → lặp 1000 lần

Decomposition of Variance

Value = Grand Average + Treatment Effect + Residual Error

Phân tích đóng góp của từng thành phần

Two-Way ANOVA

Thêm factor thứ 2 (ví dụ: weekend vs weekday)

Tính 'interaction effect' giữa 2 factors

Ví dụ: Web stickiness 4 trang (giây)

Page	1	2	3	4
Average	172	185	176	162
p-value (perm)	0.093 → not significant at 5%			

Chi-Square Test

Dùng cho dữ liệu dạng count / categorical

Mục đích

Kiểm định xem dữ liệu count có phù hợp với expected distribution không. Phổ biến nhất: $r \times c$ contingency tables — kiểm tra independence giữa các biến.

Chi-Square Statistic

Pearson Residual $R = (\text{Observed} - \text{Expected}) / \sqrt{\text{Expected}}$
 $\chi^2 = \sum R^2$ (sum over all cells)
 $df = (r - 1) \times (c - 1)$

Fisher's Exact Test

Dùng khi count quá nhỏ (< 5) $\rightarrow$ chi-square distribution không xấp xỉ tốt.
Liệt kê tất cả permutations $\rightarrow$ p-value chính xác.
Hữu ích cho web experiments với low click rates.

Ví dụ: 3 headlines, 1,000 visitors mỗi headline

	Headline A	Headline B	Headline C
Click	14	8	12
No-click	986	992	988

p-value (resampling) = 0.485 $\rightarrow$ not significant. Kết quả trong vùng chance variation.

Data Science dùng chi-square như filter (feature selection, spatial analysis) hơn là formal significance test.

Multi-Arm Bandit Algorithm

Tối ưu hóa thay vì chỉ kiểm định

Vấn đề với A/B test truyền thống

Cần chờ đủ data mới có kết luận. Trong thời gian chờ → tiếp tục dùng treatment kém. Bandit algorithm giải quyết bằng cách học và điều chỉnh trong khi thí nghiệm.

A/B Truyền thống

- Phân chia bằng nhau suốt thí nghiệm
- Chờ đủ sample → test → kết luận
- Exposure lớn cho treatment kém
- Câu hỏi: 'A hay B?'

Multi-Arm Bandit

- Shift traffic sang arm đang thắng
- Kết luận sớm hơn, adaptively
- Giảm exposure cho treatment kém
- Câu hỏi: 'Arm nào tốt nhất?' (optimization)

Epsilon-Greedy

ϵ % thời gian: explore ngẫu nhiên

$(1-\epsilon)$ % thời gian: chọn arm tốt nhất đến lúc đó

$\epsilon = 0$: purely greedy | $\epsilon = 1$: pure random A/B

Thompson Sampling

Bayesian approach với Beta prior

Sample từ phân phối và chọn arm có sample cao nhất

Update prior sau mỗi kết quả → học liên tục

Power & Sample Size

Cần bao nhiêu dữ liệu để thí nghiệm có ý nghĩa?

4 thành phần liên quan — xác định 3, tính ra thành phần còn lại:

Sample Size (n)

Số lượng observation cần thu thập trong mỗi nhóm

Effect Size

Kích thước effect tối thiểu muốn detect
Ví dụ: '10% improvement in click rate'

Power ($1 - \beta$)

Xác suất detect được effect nếu nó tồn tại
Thường đặt target = 80%

Significance Level (α)

Ngưỡng p-value để reject H_0
Thường: 0.05 hoặc 0.01

Insight quan trọng

Effect nhỏ cần sample rất lớn. Ví dụ: detect 10% boost từ 1.1% lên 1.21% click rate → cần ~120000 impressions (power=80%, α =5%).
Effect 50% boost → chỉ cần ~5500 impressions.

Degrees of Freedom (d.f.)

Số giá trị tự do trong tính toán thống kê

Khái niệm cơ bản

Số giá trị có thể vary tự do sau khi đã biết một số ràng buộc.

Ví dụ: biết mean của 10 giá trị → chỉ 9 giá trị tự do, giá trị thứ 10 bị xác định.

Variance & Std Dev

Mẫu số $n-1$ thay vì n → loại bỏ downward bias

$$S^2 = \sum (x_i - \bar{x})^2 / (n-1)$$

t-distribution

Shape phụ thuộc vào d.f. → ảnh hưởng đến p-value

Sample nhỏ hơn → đuôi dày hơn

ANOVA F-statistic

$$df(\text{treatment}) = k-1 \quad (k = \text{số nhóm})$$

$$df(\text{residuals}) = N-k$$

Regression & Dummies

Biến categorical k levels → chỉ dùng $k-1$ dummies

Tránh multicollinearity (perfect linear dependence)

Với data science: d.f. ít quan trọng trong significance testing (sample thường lớn). Quan trọng hơn trong regression với categorical variables.

Chapter 3 — Key Takeaways

A/B Testing

Randomize subjects → kiểm soát bias. Chọn 1 metric TRƯỚC.
Control group là bắt buộc.

Resampling / Permutation

Không cần giả định phân phối. Flexible, intuitive, gần với thực tế.

Multiple Testing

Càng nhiều tests → càng nhiều false positives. Dùng holdout set / cross-validation.

Multi-Arm Bandit

Optimize + explore đồng thời. Phù hợp hơn A/B thuần túy cho web testing.

Hypothesis Tests

H_0 = chance. Bảo vệ chúng ta khỏi 'fooled by random'. $p\text{-value} \neq P(H_0 \text{ đúng})$.

p-Value & alpha

p-value là xác suất dưới null model. Cần effect size + practical significance.

ANOVA / Chi-Square

Mở rộng cho nhiều nhóm/categories. Tránh multiple pairwise comparisons.

Power & Sample Size

Tính trước sample size cần thiết. Effect size nhỏ → cần sample rất lớn.