


Phân phối dữ liệu và phân phối lấy mẫu

Mục tiêu trọng tâm

Hiểu mối liên hệ giữa population, sample, bias, sampling distribution, bootstrap và các phân phối xác suất thường gặp.


Population
(phân phối thật, thường không biết)



sampling



Sample / data at hand
(phân phối thực nghiệm)



Learning outcomes

- Phân biệt population, sample, parameter và statistic.
- Giải thích vì sao random sampling vẫn quan trọng trong thời đại big data.
- Nhận diện các dạng bias: sample bias, self-selection bias, selection bias, regression to the mean.
- Mô tả sampling distribution, central limit theorem, standard error, bootstrap và confidence interval.
- Biết vai trò và bối cảnh dùng của normal, t, binomial, chi-square, F, Poisson, exponential, Weibull.

Roadmap

1

Lấy mẫu và đại diện

Population, sample, random sampling, stratified sampling, bias

2

Suy luận từ mẫu

Sampling distribution, CLT, standard error, bootstrap, confidence interval

3

Kiểm tra giả thuyết

Selection bias, vast search effect, regression to the mean

4

Phân phối xác suất


Normal, long-tail, t, binomial, chi-square, F, Poisson và các phân phối liên quan

1. Population, sample và logic của suy luận thống kê

Khái niệm cốt lõi

- **Population:** toàn bộ tập dữ liệu mà ta muốn mô tả hay suy luận; có thể là tập dữ liệu thực, lý thuyết hoặc giả định.
- **Sample:** tập con được quan sát thực sự; trong data science, ta thường chỉ có sample và empirical distribution của sample.
- **Parameter:** đại lượng của population (ví dụ: μ).
- **Statistic:** đại lượng tính từ sample (ví dụ: $\bar{x}$).
- Mục tiêu của thống kê là dùng statistic để suy luận về parameter, trong khi luôn phải kiểm soát sai số và bias.

Sơ đồ trực quan



2. Random sampling

Định nghĩa và ký hiệu


Thuật ngữ	Nội dung
N / n	Kích thước population / sample
Random sampling	Mỗi phần tử có cơ hội được chọn như nhau ở mỗi lần rút
Simple random sample	Sample thu được khi lấy ngẫu nhiên, không phân tầng
With replacement	Phần tử đã chọn được đưa lại population
Without replacement	Phần tử đã chọn không được chọn lại

- **Đại diện (representativeness)** là mục tiêu quan trọng hơn số lượng đơn thuần.
- Trong thực tế, bước khó nhất không phải “chọn ngẫu nhiên” mà là định nghĩa đúng population khả dụng để lấy mẫu.
- Với dữ liệu theo dòng thời gian (web traffic, transactions), thời điểm lấy mẫu cũng có thể tạo sai lệch.

Random sampling không đảm bảo hoàn hảo, nhưng là cơ chế tốt nhất để tránh sai lệch có hệ thống.

3. Stratified sampling

Minh họa




Khi nào nên dùng?

- Population được chia thành các strata
- Sau đó lấy random sample trong từng stratum; có thể over-sample nhóm nhỏ để đảm bảo đủ dữ liệu phân tích.
- Ví dụ: nếu chỉ lấy simple random sample, các nhóm thiểu số có thể xuất hiện quá ít.

4. Bias và sample bias

Bias

Bias trực quan



Ý nghĩa

- Bias là sai lệch có hệ thống do quy trình đo lường hoặc quy trình chọn mẫu, không phải dao động ngẫu nhiên.
- Sample bias xuất hiện khi sample khác population theo một cách có ý nghĩa và có xu hướng lặp lại nếu tiếp tục lấy mẫu theo cùng cách.
- Hầu như không có sample nào “giống population 100%”; vấn đề là sự khác biệt đó có mang tính hệ thống hay không.
- Trong thực hành, dữ liệu chất lượng cao thường quan trọng hơn dữ liệu quá nhiều nhưng lấy sai cách.

Bias làm kết quả sai theo một hướng nhất định; tăng cỡ mẫu không tự động sửa được bias.

5. Literary Digest và self-selection bias

Bias

Case study lịch sử

Literary Digest poll (1936)

- Tạp chí gửi khảo sát tới hơn 10 triệu người và dự báo Alf Landon thắng lớn.
- George Gallup chỉ khảo sát khoảng 2,000 người nhưng dự báo đúng Roosevelt chiến thắng.
- Lý do thất bại: đối tượng khảo sát thiên về người có địa vị kinh tế - xã hội cao (subscriber, người có điện thoại, ô tô).
- Bài học: sample quá lớn nhưng không đại diện vẫn cho kết luận sai.

Bias tự chọn

- Self-selection bias xảy ra khi người tham gia tự nguyện bước vào mẫu, thay vì được chọn ngẫu nhiên.
- Ví dụ quen thuộc: review nhà hàng / khách sạn / ứng dụng trên mạng xã hội.
- Người có trải nghiệm quá tốt hoặc quá xấu có động lực viết review cao hơn người bình thường.
- Dữ liệu loại này có thể hữu ích để so sánh tương đối giữa các đối tượng tương tự, nhưng không đáng tin như thước đo “sự thật tổng thể”.

6. Selection bias: data snooping, vast search effect và cách phòng tránh

Bias

Data snooping

Lục tìm dữ liệu quá mức để “kiểm” một pattern thú vị; nếu tra cứu đủ lâu, dữ liệu gần như chắc chắn sẽ “thú nhận”.

Vast search effect

Trong dữ liệu lớn, thử rất nhiều mô hình / biến / câu hỏi sẽ luôn cho ra một số kết quả có vẻ nổi bật, dù chỉ là may rủi.

After-the-fact selection

Chọn một kết quả cực đoan sau khi nhìn dữ liệu rồi kể như đó là bằng chứng mạnh là một dạng selection bias.

Cách phòng tránh: phát biểu giả thuyết trước khi kiểm định; dùng holdout/test set; dùng nhiều holdout nếu cần; kiểm tra bằng permutation / target shuffling khi nghi ngờ mối liên hệ chỉ là ngẫu nhiên.


7. Regression to the mean

Bias

Giải thích hiện tượng

- Regression to the mean xảy ra khi các quan sát cực đoan ở lần đo 1 có xu hướng được theo sau bởi các giá trị gần trung tâm hơn ở lần đo sau.
- Nó là hệ quả của selection bias: ta chọn các điểm “đỉnh” hoặc “đáy”, trong đó thường vừa có skill vừa có luck; lần sau phần luck không lặp lại đầy đủ.
- Ví dụ trong thể thao: “rookie of the year” thường sa sút ở năm hai; không nhất thiết vì anh ta kém đi, mà vì thành tích năm đầu chứa yếu tố may mắn.
- Phân biệt với linear regression: regression to the mean là một hiện tượng, không phải mô hình hồi quy tuyến tính.

Minh họa




8. Size versus quality

Nguyên tắc

- Trong nhiều bài toán ước lượng, dữ liệu sạch và được lấy mẫu tốt thường tốt hơn dữ liệu rất lớn nhưng bẩn hoặc lệch mẫu.
- Sample nhỏ hơn giúp khả thi hơn cho việc rà soát missing values, outliers, format inconsistency và manual inspection.
- Random sampling giúp giảm bias và tạo điều kiện cải thiện data quality với chi phí chấp nhận được.

Nhưng với dữ liệu rất lớn và cực kỳ sparse - như truy vấn tìm kiếm hiếm - chỉ dữ liệu khổng lồ mới chứa đủ số trường hợp liên quan để mô hình học hiệu quả.

Khi big data thật sự cần



9. Data distribution, sample statistic và sampling distribution

Inference

Data distribution

Phân phối của các giá trị dữ liệu cá thể trong sample / population.

Ví dụ

Thu nhập cá nhân bị lệch phải

Sample statistic

Một đại lượng tính từ sample: mean, median, variance, tỉ lệ,...

Ví dụ

Mean thu nhập của sample

Sampling distribution

Phân phối của statistic khi lấy nhiều sample từ cùng population.

Ví dụ


Phân phối của mean qua nhiều sample

10. Central Limit Theorem (CLT)

- CLT nói rằng phân phối của sample mean sẽ tiến gần normal distribution khi cỡ mẫu đủ lớn, ngay cả khi population không normal.
- Khi n tăng, sampling distribution của mean thường: (1) đối xứng hơn, (2) bell-shaped hơn, và (3) hẹp hơn.
- CLT là nền tảng lịch sử cho nhiều công thức suy luận cổ điển như t-distribution, confidence interval và hypothesis test.

Minh họa

Sampling distribution của mean trở nên 'chuẩn hơn' khi n tăng




11. Standard error

Công thức và diễn giải

- Standard deviation (SD) đo độ phân tán của các điểm dữ liệu cá thể.
- Standard error (SE) đo độ phân tán của một statistic - thường là mean - qua nhiều sample.
- SE nhỏ nghĩa là statistic ổn định hơn từ sample này sang sample khác.
- Với mean, công thức xấp xỉ cổ điển dựa trên sample SD và cỡ mẫu.

Quy tắc căn bậc hai của n: muốn SE giảm 2 lần phải tăng cỡ mẫu lên 4 lần.

Hệ quả theo cỡ mẫu




12. Bootstrap

Ý tưởng

- Bootstrap sample là sample được lấy với replacement từ chính sample quan sát ban đầu.
- Mục đích không phải “tạo dữ liệu mới”, mà là mô phỏng xem statistic sẽ dao động thế nào nếu ta có thể lặp lại quá trình lấy mẫu nhiều lần.
- Ưu điểm lớn: dùng được cho rất nhiều statistic và mô hình, không phụ thuộc mạnh vào giả định normality.
- Đây là phương pháp trung tâm của modern statistics để ước lượng standard error và confidence interval.

Sơ đồ



13. Thuật toán bootstrap và các ứng dụng chính

Resampling

1

Từ sample kích thước n , rút lại n quan sát với replacement.

2

Tính statistic quan tâm (mean, median, RMSE, hệ số mô hình, ...).

3

Lặp lại R lần để thu được bootstrap distribution của statistic.

4

Dùng bootstrap distribution để tính SE, vẽ histogram/boxplot, hoặc lấy percentile CI.

Ứng dụng 1: ước lượng standard error cho statistic khó có công thức

Ứng dụng 2: tạo confidence interval không cần dựa nhiều vào giả định phân phối

Ứng dụng 3: bagging trong machine learning (kết hợp nhiều mô hình trên bootstrap samples)


14. Confidence interval

Diễn giải đúng

- Confidence interval (CI) luôn đi kèm mức tin cậy, ví dụ 90% hoặc 95%.
- Một cách hiểu thực hành: đó là khoảng chứa phần trung tâm của bootstrap distribution của statistic.
- CI rộng hơn khi: mức tin cậy cao hơn, sample nhỏ hơn, hoặc dữ liệu biến động mạnh hơn.
- CI giúp chống lại xu hướng “tin tuyệt đối” vào point estimate khi báo cáo cho quản lý, nhà nghiên cứu hoặc khách hàng.

CI không trực tiếp trả lời “xác suất parameter thật nằm trong khoảng này là bao nhiêu?”; nó là phát biểu về thủ tục lấy mẫu lặp lại.

Ví dụ bootstrap CI




15. Normal distribution, z-score và chuẩn hóa

Điều cần hiểu đúng


- Normal distribution là bell curve quen thuộc; khoảng 68% dữ liệu nằm trong ± 1 SD và 95% nằm trong khoảng ± 2 SD.
- Giá trị chuẩn hóa (z-score) cho biết một điểm dữ liệu cách mean bao nhiêu độ lệch chuẩn.
- Việc chuẩn hóa dữ liệu sang z-score không làm dữ liệu trở thành normal; nó chỉ đặt dữ liệu lên cùng thang đo với standard normal.
- Trong data science, normality thường hữu ích cho lỗi đo, sample mean và một số statistic - không phải cho đa số raw data.

Đồ thị chuẩn



16. QQ-plot và long-tailed distributions

QQ-plot




Ý nghĩa thực hành

- QQ-plot so sánh quantile của sample với quantile của phân phối chuẩn; nếu các điểm bám gần đường thẳng chéo, dữ liệu gần normal.
- Với long-tailed data, các điểm lệch mạnh ở hai đầu - báo hiệu xác suất xuất hiện extreme values cao hơn nhiều so với normal.
- Ví dụ thực tế: income, stock returns, internet traffic spikes, tổn thất tài chính cực đoan.
- Nếu giả định normal quá sớm, ta có thể đánh giá thấp “black swan” và các rủi ro hiếm nhưng lớn.

17. Student's t-distribution

Đồ thị



Vai trò


- t-distribution là một họ phân phối; sample càng lớn thì t càng gần normal.
- Nó được dùng rộng rãi để mô tả phân phối của sample mean, chênh lệch giữa hai mean, hệ số hồi quy và nhiều statistic khác.
- Trong suy luận cổ điển, khoảng tin cậy cho mean thường dùng công thức t khi variance population chưa biết.
- Trong data science, ta vẫn nên biết t-distribution vì các phần mềm thống kê và A/B testing report thường in ra t-statistic.

18. Binomial distribution

Cốt lõi khái niệm

- Mỗi trial có đúng hai outcome; outcome được quan tâm thường gọi là success và ký hiệu là 1.
- Nếu xác suất success ở mỗi trial là p và số trial là n , thì số success X có phân phối binomial.
- Các ví dụ data science rất quen: click/không click, mua/không mua, fraud/không fraud, default/không default.
- Mean của binomial là np ; variance là $np(1-p)$. Với n đủ lớn và p không quá gần 0 hoặc 1, binomial có thể được xấp xỉ bởi normal.

Ví dụ xác suất




19. Chi-square và F distribution

Khi nào dùng?

- Chi-square distribution gắn với dữ liệu đếm theo nhóm/categorical counts; statistic đo mức độ khác biệt giữa observed và expected counts trong mô hình null.
- Nó là nền tảng cho goodness-of-fit test và test độc lập trong bảng chéo.
- F-distribution được dùng trong ANOVA và linear regression; nó so sánh biến thiên giữa nhóm / do mô hình giải thích với biến thiên còn lại.
- Cả hai đều là reference distribution cho kiểm định giả thuyết, không phải mô tả trực tiếp raw data.

Các đường cong tham chiếu




20. Poisson, exponential và Weibull

So sánh nhanh

- Poisson distribution: số sự kiện trong một đơn vị thời gian hoặc không gian khi sự kiện xảy ra với tốc độ trung bình λ .
- Exponential distribution: thời gian (hoặc khoảng cách) giữa hai sự kiện liên tiếp khi tốc độ λ là hằng số.
- Weibull distribution: mở rộng của exponential; cho phép tốc độ xảy ra sự kiện thay đổi theo thời gian qua shape parameter β .
- Đây là họ phân phối quan trọng cho queuing, reliability, time-to-failure, service operations và event simulation.

Minh họa



21. Summary

Phân phối	Đối tượng mô hình hóa	Tham số chính	Ứng dụng thường gặp	Điểm cần nhớ
Normal	Errors, averages, standardized values	μ, σ	Sai số đo; xấp xỉ sampling distribution	Không mô tả tốt phần lớn raw data
t	Sample mean / hệ số thống kê	df	CI, hypothesis test, regression output	Đuôi dày hơn normal; n lớn thì gần normal
Binomial	Số success trong n trials	n, p	Conversion, fraud, click, survival	Mean = np; Var = np(1-p)
Chi-square	Observed vs expected counts	df	Goodness-of-fit, independence test	Dùng cho counts theo nhóm
F	Tỉ số phương sai	df1, df2	ANOVA, regression	So sánh signal với residual variation
Poisson	Số sự kiện / khoảng	λ	Traffic, arrivals, defects	Mean = Var = λ khi mô hình chuẩn
Exponential	Thời gian giữa hai sự kiện	λ	Inter-arrival time, time-to-service	Giả định event rate hằng số
Weibull	Time to failure với rate thay đổi	β, η	Reliability, lifetime modeling	$\beta > 1$: risk tăng theo thời gian